

Analyse des facteurs associés à la survie globale des patients atteints d'un carcinome épidermoïde de la tête et du cou

Nayla

2026-07-26

1. Importation des données

```
library (DBI)
library (RMariaDB)
library (tidyverse)

con<-dbConnect(
  MariaDB(),
  dbname="hnsc",
  host="localhost",
  port=3306,
  user="root",
  password="")

df_surv<-dbGetQuery(con,
  "SELECT* FROM dataset_surv_vw")
```

2. Nettoyage des données résiduel et gestion des valeurs manquantes

```
colSums(is.na(df_surv))
df_surv<-df_surv %>%
  mutate(hpv_status=ifelse(hpv_status=="",NA,hpv_status))

table(df_surv$smoking_history, useNA = "always")
df_test <- na.omit(df_surv$smoking_history)
length(df_test)

df_surv_clean<-df_surv %>%
  drop_na(smoking_history,tabac_status,alcohol_use,clinical_stage) %>%
  mutate(alcohol_use=factor(alcohol_use),
    smoking_history=factor(smoking_history,
      levels = c(1,2,3,4,5),
      labels=c("non-smoker","current",
        "reformed smoker>15y","reformed smoker<=15y",
        "other"))),
```

```

tabac_status=factor(tabac_status),
gender=factor(gender),
clinical_stage=factor(clinical_stage),
pathologic_stage=factor(pathologic_stage),
hpv_status=factor(hpv_status),
lymphvascular_invasion=factor(lymphvascular_invasion),
perineural_invasion=factor(perineural_invasion))

```

Gestion des données abérantes

```

donnee_aberrante <- df_surv_clean %>%
  filter(age_at_diagnosis<=0 | time<=0)
str(donnee_aberrante)

#Exclusion du patient
df_surv_clean<-df_surv_clean %>%
  filter(patient_id != "TCGA-CQ-A4CA")
str(df_surv_clean)

#suppression de la modalité "other" du statut tabagique ( 0 décès dans le modèle de survie)
df_surv_clean<-df_surv_clean %>%
  filter(smoking_history != "other") %>%
  mutate(smoking_history = droplevels(smoking_history))

```

4. Analyse descriptive exploratoire

Description de l'échantillon

Table 1: décès et données de censure selon le genre

	FEMALE	MALE
0	22.46	77.54
1	30.92	69.08

Table 2: décès et données de censure selon le statut tabagique

	0	1
non-smoker	26.09	19.81
current	31.88	36.71
reformed smoker>15y	14.49	14.49
reformed smoker<=15y	27.54	28.99

Table 3: Proportion de consommateur d'alcool dans l'échantillon

Var1	Freq
NO	30.64
YES	69.36

Table 4: décès et données de censure selon le stade clinique

	0	1
I	4.35	2.90
II	19.20	18.84
III	21.01	21.26
IVA	53.26	52.17
IVB	1.81	2.42
IVC	0.36	2.42

Représentations graphiques

```
df_surv_clean<-df_surv_clean %>%
  mutate(classe_age_at_diagnosis=case_when(age_at_diagnosis>=70~"+70 years",
                                           age_at_diagnosis>=60~"60-69 years",
                                           age_at_diagnosis>=50~"50-59 years",
                                           age_at_diagnosis>=40~"40-49 years",
                                           age_at_diagnosis<40~"<40 years"))

df_surv_clean$classe_age_at_diagnosis<-factor(df_surv_clean$classe_age_at_diagnosis,
                                             levels=c("<40 years",
                                                    "40-49 years",
                                                    "50-59 years",
                                                    "60-69 years",
                                                    "+70 years"))

#age

df_plot<-df_surv_clean %>%
  group_by(classe_age_at_diagnosis) %>%
  summarise(pct_deces=mean(event==1)*100
)

#genre

df_plot_genre<-df_surv_clean %>%
  group_by(classe_age_at_diagnosis,gender) %>%
  summarise(pct_deces=mean(event==1)*100)

#Stade clinique

df_plot_clinic <- df_surv_clean %>%
  filter(event == 1) %>%
  group_by(classe_age_at_diagnosis, clinical_stage) %>%
```

```

summarise(
  n = n(),
  .groups = "drop"
) %>%
group_by(classe_age_at_diagnosis) %>%
mutate(
  pct = n / sum(n) * 100
)

#tabac

data_tabac<-df_surv_clean %>%
  filter(event==1) %>%
  group_by(smoking_history) %>%
  summarise(n=n()) %>%
  ungroup () %>%
  mutate(pct_tabac=n/sum(n)*100)

data_tabac_status<-df_surv_clean %>%
  filter(!smoking_history=="other") %>%
  group_by(smoking_history) %>%
  summarise(n=n(),
            deces=sum(event==1)) %>%
  mutate(pct_deces=deces/n*100)

#alcool
df_alcool <-df_surv_clean %>%
  group_by(alcokol_use) %>%
  summarise(deces=mean(event==1)*100)


```

Graphique 1 : Deaths and censured observations by age group

```


ggplot(data=df_surv_clean)+aes(x=classe_age_at_diagnosis, fill = factor(event))+
  geom_bar(position = "dodge")+
  labs(title = "Deaths and censured observations by age group",
       y="count",
       x="",
       fill="Event")+
  theme_minimal()

```




Graphique 2 : Deaths and censored observations by gender

```
ggplot(df_plot_genre)+aes(x=classe_age_at_diagnosis,y=pct_deces,fill = gender)+
  geom_bar(stat = "identity",position = "dodge")+
  geom_text(aes(label=paste0(round(pct_deces,2),"%"),
    position=position_dodge(width = 0.9),
    vjust=-0.3)+
  labs(title="Deaths and censured observations by gender",
    x="",
    y="Death (in %)",
    fill="Gender")+
  theme_minimal()
```



graphique 3 : Deaths by clinical stage


```
ggplot(data=df_plot_clinic)+aes(x=classe_age_at_diagnosis,y=pct,fill=clinical_stage)+
  geom_bar(stat="identity")+
  labs(title="Deaths by clinical stage",
        y="Death (in %)",
        x="",
        fill="Clinical stage")+
  theme_minimal()
```



graphique 4 : Deaths by clinical stage

```
ggplot(data = data_tabac)+aes(x="",y=pct_tabac,fill = smoking_history)+
  geom_bar(stat = "identity",width=1)+
  coord_polar(theta = "y")+
  geom_text(
    aes(label = paste0(round(pct_tabac,2),"%")),
    position=position_stack(vjust = 0.5))+
  labs(title="Distribution of Deaths by Smoking Status",
    x="",
    y="",
    fill="Smoking status")+
  theme_void()
```


Distribution of Deaths by Smoking Status



graphique 5 : Deaths by alcohol consumption

```
ggplot(df_alcool)+aes(x="",y=deces,fill = alcohol_use)+  
  geom_bar(stat="identity",position = "stack")+  
  coord_polar(theta = "y")+  
  geom_text(aes(label=paste0(round(deces,2),"%")),  
            position=position_stack(vjust=0.5))+  
  labs(title="Deaths by alcohol consumption",  
        x="",  
        y="Deaths (%)",  
        fill="Alcohol consumption")+  
  theme_void()
```

Deaths by alcohol consumption



Inférences statistiques

Test de proportion : consommation d'alcool

```
tab_alcohol<- table(df_surv_clean$alcohol_use,df_surv_clean$event)
prop.test(x=tab_alcohol[,2],
          n=rowSums(tab_alcohol)
          )
```

```
##
## 2-sample test for equality of proportions with continuity correction
##
## data:  tab_alcohol[, 2] out of rowSums(tab_alcohol)
## X-squared = 1.0231, df = 1, p-value = 0.3118
## alternative hypothesis: two.sided
## 95 percent confidence interval:
## -0.04670517 0.15525701
## sample estimates:
##      prop 1      prop 2
## 0.4662162 0.4119403
```

Test de proportion non significatif : Différence de proportion non statistiquement significatif dans l'échantillon

Association entre le genre et l'événement:

```
chisq.test(table(df_surv_clean$gender, df_surv_clean$event))
```

```
##  
## Pearson's Chi-squared test with Yates' continuity correction  
##  
## data:  table(df_surv_clean$gender, df_surv_clean$event)  
## X-squared = 3.957, df = 1, p-value = 0.04668
```

Identification d'un lien significatif entre le genre et l'événement par le test de chi-deux au seuil de 5%

Association effet du tabac et de alcool : test de chi-deux

```
chisq.test(table(df_surv_clean$smoking_history, df_surv_clean$alcohol_use))
```

```
##  
## Pearson's Chi-squared test  
##  
## data:  table(df_surv_clean$smoking_history, df_surv_clean$alcohol_use)  
## X-squared = 37.993, df = 3, p-value = 2.836e-08
```

Test significatif : Existence d'une association entre la consommation d'alcool et le statut tabagique, la repartition des consommateurs d'alcool n'est donc pas la même selon le statut tabagique

	NO	YES
non-smoker	37.16	17.31
current	20.95	39.70
reformed smoker>15y	20.95	11.64
reformed smoker<=15y	20.95	31.34

81% des fumeurs courants boivent de l'alcool contre 51% des non fumeurs et 77% des fumeurs ayant arrêté il y a moins de 15ans

Analyse du temps de survie

Var1	Freq
0	0.57
1	0.43

43% des patients sont décédés contre 57% qui n'ont pas connu l'événement au cours de la durée de l'étude (censurée). Le temps de suivie médian est de 656 jours et le temps de suivi maximal est de 6417 jours, soit environs 17ans

5. Modèle de survie : Estimateur Kaplan-Meier et modèle de COX

Kaplan-meier et inférences

```
#Chargement des packages

library(survival)
library(survminer)

#Préparation de l'objet de survie

objet_surv<-Surv(time=df_surv_clean$time, event=df_surv_clean$event)

#Estimation de la survie par classe d'âge

surv_fit_age<-survfit(objet_surv~classe_age_at_diagnosis,data = df_surv_clean)

#Estimation de la survie selon le genre

surv_fit_genre<-survfit(objet_surv~gender,data=df_surv_clean)

#Estimation de la survie selon le statut tabagique

surv_fit_tabac<-survfit(objet_surv~smoking_history,data = df_surv_clean)


#Estimation de la survie selon la consommation d'alcool

surv_fit_alcool<-survfit(objet_surv~alcohol_use,data = df_surv_clean)


ggsurvplot(surv_fit_age,
            data=df_surv_clean,
            pval = TRUE,
            title="Courbes de survie par classe d'âge")
```


Courbes de survie par classe d'âge

lasse_age_at_diagnosis=40-49 years classe_age_at_diagnosis=50-59 years classe_age_at_



```
ggsurvplot(  
  surv_fit_genre,  
  data = df_surv_clean,  
  pval = TRUE,  
  risk.table = FALSE,  
  conf.int = FALSE,  
  title="Kaplan-Meier survival curves by gender"  
)
```

Kaplan–Meier survival curves by gender



#Test Log-Rank : difference de survie selon le genre


```
test_surv_genre<-survdifff(objet_surv~gender,data=df_surv_clean)
```

p-value : 0.06 > 5% : Une tendance à une différence de survie selon le sexe était observée, sans atteindre le seuil de significativité statistique.

```
ggsurvplot(surv_fit_tabac,  
  data=df_surv_clean,  
  pval = TRUE,  
  title="Courbes de survie selon le statut tabagique")
```

Courbes de survie selon le statut tabagique

ory=non-smoker smoking_history=current smoking_history=reformed smoker>15y smol




```
#Test de Log-Rank : difference de survie
test_surv_tabac<-survdif(objet_surv~smoking_history,data=df_surv_clean)
```

On ne met pas en évidence de différence statistiquement significative des courbes de survie selon le statut tabagique. ($p=0.1$) Mais les décès dans le groupe current est supérieur aux décès attendus si les courbes étaient identiques (hypothèse d'égalité des courbes)

```
ggsurvplot(surv_fit_alcool,
            data=df_surv_clean,
            pval=TRUE,
            title="Courbes de survie selon la consommation d'alcool")
```

Courbes de survie selon la consommation d'alcool



```
test_surv_alcool<-survdif(objet_surv~alcohol_use,data=df_surv_clean)
```

Pas de différences significatives révélés entre la survie des consommateurs d'alcool et celle des non-consommateurs.

Modèles de COX

#regroupement des stades cliniques : Pour palier le manque de representation dans les catégories

#Verification du nombre de décès par categorie (information apportée par la variable)

```
df_surv_clean %>%  
  group_by(clinical_stage) %>%  
  summarise(n=n(),  
            deces=sum(event==1),  
            pct_deces=mean(event==1)*100)
```

```
## # A tibble: 6 x 4  
##   clinical_stage      n deces pct_deces  
##   <fct>          <int> <int>   <dbl>  
## 1 " I"             18     6    33.3  
## 2 " II"            92    39    42.4  
## 3 " III"          102    44    43.1
```

```
## 4 " IVA"          255   108    42.4
## 5 " IVB"           10    5     50
## 6 " IVC"            6    5    83.3
```

```
#Regroupement
df_surv_clean<-df_surv_clean %>%
  mutate(stage_group=case_when(
    clinical_stage %in% c(" I"," II")~"I-II",
    clinical_stage %in% c(" III"," IVA")~"III-IVA",
    clinical_stage %in% c(" IVB"," IVC")~"IVB-IVC"
  ))
#Verification du nombre de décès par nouvelle catégorie

df_surv_clean%>%
  group_by(stage_group) %>%
  summarise(n=n(),
            deces=sum(event==1),
            pct_deces=mean(event==1))
```

```
## # A tibble: 3 x 4
##   stage_group      n deces pct_deces
##   <chr>         <int> <int>   <dbl>
## 1 I-II          110    45    0.409
## 2 III-IVA       357   152    0.426
## 3 IVB-IVC       16    10    0.625
```

```
#Modèle de cox simple :
```

```
model_cox<-coxph(objet_surv~age_at_diagnosis+gender+smoking_history+alcohol_use+stage_group,data=df_surv)
summary(model_cox)
```

Résultats

```
gtsummary::tbl_regression(model_cox,exponentiate = TRUE) %>%
  gtsummary::as_kable()
```

Characteristic	HR	95% CI	p-value
age_at_diagnosis	1.02	1.01, 1.04	<0.001
gender			
FEMALE	—	—	
MALE	0.80	0.58, 1.11	0.2
smoking_history			
non-smoker	—	—	
current	1.51	1.01, 2.25	0.043
reformed smoker>15y	0.74	0.45, 1.23	0.2
reformed smoker<=15y	1.17	0.77, 1.77	0.5
alcohol_use			
NO	—	—	
YES	0.97	0.71, 1.33	0.9

Characteristic	HR	95% CI	p-value
stage_group			
I-II	—	—	
III-IVA	1.19	0.84, 1.69	0.3
IVB-IVC	1.75	0.87, 3.54	0.12

Modèle de Cox avec interaction des effets de l'alcool et du tabac

```
model_cox_2<-coxph(objet_surv~age_at_diagnosis+gender+smoking_history+
  alcohol_use+stage_group+
  alcohol_use*smoking_history,
  data=df_surv_clean)
```

```
anova(model_cox,model_cox_2)
```

Test du rapport de vraisemblance : Vérification de l'ajustement des 2 modèles (effet de l'interactions)

```
## Analysis of Deviance Table
## Cox model: response is objet_surv
## Model 1: ~ age_at_diagnosis + gender + smoking_history + alcohol_use + stage_group
## Model 2: ~ age_at_diagnosis + gender + smoking_history + alcohol_use + stage_group + alcohol_use * 
##      loglik  Chisq Df Pr(>|Chi|)
## 1 -1109.2
## 2 -1107.2 3.9711 3      0.2646
```


L'interaction n'améliore pas significativement le modèle, le modèle sans interaction est alors plus pertinent.

Vérification des risques proportionnels du modèle retenu

```
test_shoefeld<-cox.zph(model_cox)
```

Le modèle dans son ensemble respecte l'hypothèse des risques proportionnels, ce modèle de cox ne viole pas l'hypothèse mais Variable alcohol peut compromettre l'hypothèse

```
plot(test_shoefeld,var="alcohol_use")
```



La courbe est globalement horizontale autour de 0, la variable “alcool” ne compromet pas l’hypothèse des risques proportionnels du modèle.

Modèle de survie 2 : étude de l’association entre la durée de survie et le HPV

```
model_surv_3<- coxph(objet_surv~age_at_diagnosis+gender
  +smoking_history+alcohol_use
  +hpv_status,data=df_surv_clean)
summary(model_surv_3)
```

Résultats

```
gtsummary::tbl_regression(model_surv_3,exponentiate = TRUE) %>%
  gtsummary::as_kable()
```

Characteristic	HR	95% CI	p-value
age_at_diagnosis	1.00	0.96, 1.04	0.9
gender			
FEMALE	—	—	
MALE	1.04	0.37, 2.89	>0.9
smoking_history			


Characteristic	HR	95% CI	p-value
non-smoker	—	—	
current	1.29	0.33, 5.04	0.7
reformed smoker>15y	0.88	0.15, 5.29	0.9
reformed smoker<=15y	1.26	0.30, 5.26	0.8
alcohol_use			
NO	—	—	
YES	2.63	0.77, 9.06	0.12
hpv_status			
Negative	—	—	
Positive	0.28	0.08, 0.95	0.042

Test de Log Rank: Différence de survie entre les patients ayant un test HPV positif et ceux ayant un test positif

```
surv_hpv <- survfit(objet_surv~hpv_status,data=df_surv_clean)
survdifff(objet_surv~hpv_status,data=df_surv_clean)
```

```
ggsurvplot(surv_hpv,
  data= df_surv_clean,
  pval=TRUE,
  title ="Kaplan-Meier survival curves by HPV status")
```

Kaplan–Meier survival curves by HPV status



Une différence statistiquement significative entre les patients ayant un test HPV positif et ceux ayant un test négatif : Les personnes négatives présentent des probabilités de survie au cours du suivi.

Test shoenfeld et verification de l'hypothèse des risques proportionnels

```
cox.zph(model_surv_3)
```

```
##               chisq df      p
## age_at_diagnosis 0.2513  1 0.616
## gender           2.8628  1 0.091
## smoking_history  3.2052  3 0.361
## alcohol_use      0.3662  1 0.545
## hpv_status       0.0694  1 0.792
## GLOBAL          6.6781  7 0.463
```

Les résidus de Schoenfeld montrent qu'aucune des covariables ne présente de violation significative de cette hypothèse (toutes les $p > 0,05$). Le test global n'est pas significatif, indiquant que l'hypothèse des risques proportionnels est respectée.